

Transporto priemonių siluetų klasifikavimas

Egzamino darbo ataskaita

Kirilas Šeršniovas | PEPfm-26 | Intelektualiosios sistemos

Atnaujinta 2026-09-29. Pradinis palyginimas iš results/main/; vėlesni tiriamieji bandymai iš atskirų results/ aplankų.

Trumpa išvada

Pradiniame iš anksto apibrėžtame bandyme geriausias buvo SVM su RBF branduoliu: išorinis Macro-F1 0,842, palyginti su 5-NN 0,708. Vėliau, jau matant šio testo rezultatus, platesnė SVM paieška pasiekė 0,852, o naujas TabPFN v2 kandidatas - 0,869. Pastarasis pagerino bendrą rodiklį, tačiau Opel ir Saab tarpusavio supainiojimų nesumažino, palyginti su platesniu SVM (525 ir 522). Vėlesni bandymai tiriamieji, todėl nepriklausomai patvirtinto pranašumo neteigiame.

Ataskaita apima užduotį, duomenų ir vertinimo protokolą, metodų palyginimą, abliaciją, atsparumą, klaidų analizę ir atkūrimą. B priede yra naujų bandymų lentelė bei grafikai. AI_POKALBIU_ISTORIJA.md saugo užfiksuotus pokalbių tekstus ir aiškiai pažymėtas vėlesnių etapų santraukas; sprendimų patikros pateiktos ai_log.md.

1. Užduotis ir sprendimo apimtis

Užduoties tikslas - pagal iš transporto priemonės silueto jau apskaičiuotus geometrinius požymius nustatyti vieną iš keturių klasių: bus, opel, saab arba van. Šaltinis - OpenML Vehicle, duomenų rinkinio ID 54, 1 versija. Pradinės nuotraukos rinkinyje nepateiktos, todėl sprendimas pradeda darbą nuo 18 skaitinių požymių, o ne nuo vaizdo.

Galutinis darbas turėjo pateikti dvi paprastas bazes, bent du intelektualiuosius metodus, vienodą vertinimo protokolą, abliaciją arba jautrumą, atsparumo bandymą, rezultatų lentelę ir grafiką, klaidų analizę bei atkūrimo ir AI naudojimo dokumentaciją. Visas originalios užduoties tekstas lietuvių kalba ir vertinimo balai perkelti į A priedą.

Kolokviumo plano įgyvendinimas

Plane pasirinkta	Įgyvendinimas / įrodymas
kNN ir centroidų bazės	Du atskaitos metodai; rezultatai bendroje lentelėje.
SVM RBF, MLP, RBF tinklas	Visi trys išmokyti ir įvertinti 50 vienodų išorinių skaidinių.
SVM hipotezė: $> 0,02$ virš geriausios bazės	Gautas porinis skirtumas $+0,134$; pataisytas 95 % intervalas $[+0,097; +0,170]$.
Abliacija ir atsparumas	Tiesinis SVM, SVM be mastelio keitimo, triukšmas ir trūkstami duomenys.
Atkuriamumas ir skaičiavimo biudžetas	Fiksuotos sėklos, konfigūracija, 18 951 pritaikymas, išsaugoti CSV ir modelis.

Pradinis MLP ir RBF tinklo hiperparametrų tinklas viršijo 20 000 pritaikymų planą. Prieš pakartotinį galutinį paleidimą jis sumažintas ir pakeitimas užregistruotas plano_patikslinimai.md. Kadangi ankstesni rezultatai jau buvo žinomi, pakartotinis paleidimas nėra nepriklausomas išankstinės hipotezės patvirtinimas.

2. Duomenys ir eksperimento protokolas

OpenML Vehicle v1 turi 846 įrašus ir 18 skaitinių silueto požymių: bus - 218, opel - 212, saab - 217, van - 199. Duomenų MD5: fbba18157b188f309d772f9ca4e578f5. Duomenų gavimas, stulpelių skaičius, leistinos klasės ir kontrolinė suma tikrinami prieš eksperimentą.

Naudota 5 pakartojimai po 10 stratifikuotų išorinių skaidinių - iš viso 50 išorinių bandymų. Kiekvienas metodas gauna tas pačias mokymo ir bandymo indeksų poras. Kiekvienos išorinės mokymo dalies viduje hiperparametrai parenkami 5 dalių kryžiniu vertinimu pagal Macro-F1; išorinis bandymo skaidinys tam nenaudojamas.

Kiekviename mokyme trūkstamų reikšmių medianos ir standartizavimo parametrai apskaičiuojami tik iš mokymo duomenų. Tos pačios išmoktos transformacijos taikomos bandymo daliai. Pagrindinės metrikos: Macro-F1 - keturių klasių F1 vidurkis; balanced accuracy - keturių klasių jautrumų vidurkis. Painiavos matrica pateikiama klaidų analizei.

3. Metodai ir formulės ryšys su realizacija

Vaidmuo	Metodas	Trumpas veikimo principas
Atskaitos	5-NN	Klasė pagal penkis artimiausius mokymo objektus.
Atskaitos	Artimiausias centroidas	Parenkamas arčiausias klasės požymių vidurkis.
Pagrindinis	SVM RBF	Netiesinė skiriamoji riba su C ir gamma reguliavimu.
Alternatyva	MLP	Daugiasluoksnis perceptronas su reguliavimu ir ankstyvu stabdymu.
Alternatyva	RBF tinklas	KMeans centrai, Gauso aktyvacijos, Ridge išvestis.

SVM naudotas standartizavimas $z_j = (x_j - \mu_j) / s_j$ ir RBF branduolys $K(z, z') = \exp(-\gamma \|z - z'\|^2)$. Čia μ_j ir s_j yra tik mokymo dalies statistikos; γ valdo lokalumą, o C - maržos ir mokymo klaidų kompromisą. src/models.py funkcija build_pipeline jungia SimpleImputer, StandardScaler ir SVC(kernel="rbf"). C ir gamma kandidatų atranka atliekama run_experiment.py vidinėje CV. Keturioms klasėms SVC naudoja šešis porinius sprendimus.

RBF tinklo realizacijoje `src/models.py` klasė `RBFNetwork.fit` apskaičiuoja KMeans centrus ir Ridge išvesties sluoksni. Šis metodas yra atskiras nuo SVM RBF branduolio: vienoda radialinių funkcijų idėja nereiškia vienodo mokymo algoritmo.

Formulės ir konkrečios programos vietos

Formulė arba taisyklė	Programos vieta	Kas ten atliekama
$z_j = (x_j - \mu_j) / s_j$	<code>src/models.py: build_pipeline</code>	StandardScaler mokomas tik atitinkamo mokymo skaidinio duomenimis.
$K(z, z') = \exp(-\gamma \ z - z'\ ^2)$	<code>src/models.py: build_pipeline("svm")</code>	SVC RBF branduolys; C ir gamma kandidatai vertinami vidinėje CV.
Macro-F1 = keturių klasių F1 vidurkis	<code>run_experiment.py: metrics</code>	Ta pati pagrindinė metrika skaičiuojama kiekviename išoriniame teste.

Iš anksto apibrėžta vidinė paieška

Metodas	Derinti parametrai	Atrankos taisyklė
SVM RBF	C: 0,1; 1; 10; 100. Gamma: scale; 0,001; 0,01; 0,1; 1.	Geriausias vidinis Macro-F1.
MLP	Sluoksniai: 16; 32; (32,16). Alpha: 0,0001; 0,01. Mokymosi žingsnis: 0,001; 0,01.	Geriausias vidinis Macro-F1.
RBF tinklas	Centrai: 8; 16; 32. Plotis: 0,5; 1. Ridge alpha: 0,001; 0,01; 0,1.	Geriausias vidinis Macro-F1.

MLP ir RBF parametrai atitinka prieš pakartotinį galutinį paleidimą dokumentuotą sumažintą tinklę; abiejų baseline parametrai nebuvo derinami.

4. Pagrindiniai rezultatai

Metodas	Vaidmuo	Macro-F1 ± SD	Balanced acc. ± SD	Mokymas, s
SVM RBF	pagrindinis	0.842 ± 0.031	0.843 ± 0.030	3.812
SVM tiesinis	abliacija	0.794 ± 0.036	0.797 ± 0.036	2.012
MLP	intelektualus	0.775 ± 0.047	0.781 ± 0.044	5.481
SVM be stand.	abliacija	0.756 ± 0.040	0.765 ± 0.037	5.031
RBF tinklas	intelektualus	0.727 ± 0.037	0.741 ± 0.034	9.524
5-NN	bazė	0.708 ± 0.053	0.714 ± 0.052	0.008
Centroidas	bazė	0.441 ± 0.052	0.462 ± 0.047	0.007


Lentelėje pateiktas 50 išorinių skaidinių vidurkis ir standartinis nuokrypis. Šie skaidiniai priklausomi, nes tie patys įrašai vertinami per penkis pakartojimus; todėl SD nėra nepriklausomų 50 imčių paklaida. Laikas yra vidutinis vieno išorinio modelio mokymo laikas su vidine paieška.

SVM RBF pranoko abi privalomas bazes ir kitas intelektualesias alternatyvas pagal iš anksto pasirinktą Macro-F1. SVM ir geresnio baseline, 5-NN, porinis skirtumas +0,134; pataisytas 95 % intervalas [+0,097; +0,170]. SVM buvo geresnis visuose penkiuose pakartojimuose. Tai dera su hipoteze, kad netiesinė riba naudinga persidengiančioms klasėms, nors vien šis bandymas neįrodo tikslaus laimėjimo mechanizmo.

Porinis SVM palyginimas tuose pačiuose skaidiniuose

Palyginimas su	Vidutinis SVM Macro-F1 skirtumas	SVM geresnis skaidiniuose
5-NN	+0.134	50/50
Centroidas	+0.401	50/50
MLP	+0.067	42/50
RBF tinklas	+0.115	50/50
SVM tiesinis	+0.047	48/50
SVM be stand.	+0.086	49/50


Šis pergalių skaičius yra aprašomasis: tie patys objektai kartojasi, todėl 50 skaidinių nėra 50 nepriklausomų bandymų. Pataisytas intervalas pateiktas tik iš anksto numatytam SVM ir geriausio baseline, 5-NN, hipotezės palyginimui.



1 pav. Macro-F1 pasiskirstymas tų pačių išorinių skaidinių vertinime.

5. Abliacija ir požymių jautrumas

Pakeitus RBF branduolį tiesiniu, Macro-F1 sumažėjo nuo 0,842 iki 0,794 (-0,047). Pašalinus standartizavimą jis sumažėjo iki 0,756 (-0,086). Abu variantai buvo vertinti tais pačiais išoriniais skaidiniais; jų hiperparametrai derinti tik vidinėje mokymo dalyje.




2 pav. Didžiausi vidutiniai Macro-F1 kritimai permutavus po vieną požymį tik išorinėje bandymo dalyje.

Svarbiausi pagal šį diagnostinį bandymą: HOLLOWS_RATIO (0,234), RADIUS_RATIO (0,216), SKEWNESS_ABOUT_MAJOR (0,171). Permutacijos kritimas rodo šio išmokyto modelio jautrumą, o ne priežastinę požymio įtaką. Rezultatai nebuvo naudoti modeliui perrinkti.

6. Atsparumo bandymai

Visiems penkiems pagrindiniams metodams tie patys išoriniai bandymo objektai buvo perturbuoti vienodai. Gauso triukšmo lygiai: 0,05, 0,10 ir 0,20 nuo atitinkamos mokymo dalies požymio standartinio nuokrypio. Atskirai paslėpta 5 % ir 10 % bandymo langelių, kuriuos užpildo tik mokymo dalyje išmoktas medianų imputatorius. Kiekvienam lygiui panaudota 20 fiksuotų realizacijų.



3 pav. Metodų Macro-F1, didinant triukšmą ir trūkstamų požymių dalį. Nulinis taškas - švarus išorinis testas.

Metodas	Švarus	Triukšmas 0,20	Pokytis	Trūksta 10 %	Pokytis
Centroidas	0.441	0.438	-0.003	0.440	-0.001
5-NN	0.708	0.698	-0.010	0.679	-0.030
SVM RBF	0.842	0.765	-0.077	0.724	-0.118
MLP	0.775	0.740	-0.035	0.711	-0.064
RBF tinklas	0.727	0.712	-0.014	0.688	-0.039

SVM išlieka pirmas esant abiem stipriausiems bandytiems trikdžiams, tačiau jo kritimas didžiausias: -0,077 su triukšmu 0,20 ir -0,118, kai trūksta 10 % langelių. Trikdžio realizacijos ir CV skaidiniai nėra nepriklausomos naujos duomenų imtys. Šie testai neapima naujų kamerų, naujų automobilių modelių ar laiko poslinkio.

7. Klaidų analizė

Sujungtoje SVM painiavos matricoje kiekvienas iš 846 įrašų pasirodo penkis kartus. Daugiausia painiavos tarp Opel ir Saab: Opel priskirtas Saab 290 kartų, Saab priskirtas Opel 273 kartus. Autobusai ir furgonai atpažinti geriau. Ši matrica nėra 4 230 skirtingų transporto priemonių.


Tikroji klasė	Preciziškumas	Jautrumas	F1	Proгноzių sk.
bus	0.980	0.972	0.976	1090
opel	0.723	0.710	0.716	1060
saab	0.725	0.717	0.721	1085
van	0.937	0.973	0.955	995

Lentelės klasės metrikos apskaičiuotos sujungus visų penkių pakartojimų išorines prognozes. Todėl čia pateiktas bendras keturių klasių F1 vidurkis gali nežymiai skirtis nuo pagrindinio 50 skaidinių Macro-F1 vidurkio 0,842. Support reiškia pakartotas išorines prognozes, ne skirtingus įrašus.

Opel-Saab kryptinių klaidų suma yra 563 iš 671 visų SVM klaidų (83,9 %). Tai pagrindinė keturių klasių uždavinio silpnoji vieta; dviejų modelių painiojimas nepakeičia reikalavimo teisingai klasifikuoti keturias atskiras klases.

Kaip skaityti metrikas: skaitinis Opel pavyzdys


Penkis kartus kartoto išorinio testo painiavos matricoje yra 1 060 tikrųjų Opel vertinimų. Iš jų 753 teisingai priskirti Opel (TP), 307 priskirti kitoms klasėms (FN). Dar 289 kitų klasių objektai klaidingai pavadinti Opel (FP). Preciziškumas $P = TP/(TP+FP) = 753/(753+289) = 0,723$: maždaug 72 iš 100 Opel prognozių yra teisingos. Jautrumas $R = TP/(TP+FN) = 753/1\,060 = 0,710$: aptinkama apie 71 iš 100 tikrųjų Opel. $F1 = 2TP/(2TP+FP+FN) = 1\,506/2\,102 = 0,716$. Macro-F1 yra keturių klasių F1 vidurkis; subalansuotas tikslumas - jų jautrumų vidurkis. Tikslumas nėra tas pats, kas preciziškumas. Šie 1 060 vertinimų atitinka 212 skirtingų Opel įrašų penkis kartus.



4 pav. SVM RBF painiavos matrica, sudaryta tik iš išorinių prognozių.

Įrašo indeksas	Tikroji klasė	Prognozė	Diagnostinis tarpas
815	bus	van	2.282
297	saab	opel	2.166
285	saab	opel	2.157
72	opel	saab	1.899
148	saab	opel	1.899

Pavyzdžiai rodo klaidingas prognozes su didžiausiu diagnostiniu porinio sprendimo tarpu. Šis tarpas nėra kalibruota tikimybė ir neleidžia teigti, kad konkretus įrašas buvo pažymėtas klaidingai. Originalių silueto vaizdų rinkinyje nėra.



5 pav. Kiek kartų tas pats įrašas buvo klaidingai klasifikuotas per penkis CV pakartojimus.

647 skirtingi įrašai teisingai klasifikuoti visus penkis kartus, o 81 - neteisingai visus penkis. Paskutinis grafiko stulpelis reiškia penkias to paties įrašo klaidas, o ne prastesnį penktą pakartojimą.

8. Atkuriamumas, ribos ir gynimas

Pagrindinis eksperimentas kartojamas iš projekto aplanko komanda: `python run_experiment.py --config configs/main.yaml`. Priklausomybės nurodytos `requirements.txt`, sėklos - 2026, 2027, 2028, 2029, 2030. Atsisiuntimo instrukcija ir duomenų kontrolinė suma pateiktos `README.md`. Pilni skaidinių rezultatai, prognozės, patikros JSON ir galutinis SVM modelis saugomi `results/main/`.

Pakartotiniam paleidimui užregistruota 18 951 modelio pritaikymas ir apie 26,8 min. iki pirmos ataskaitos. Patikros scenarijus perskaičiuoja metrikas iš išsaugotų prognozių, tikrina tuos pačius skaidinius, painiavos matricas ir išsaugoto modelio vientisumą. Tai rodo techninį atkuriamumą nurodytoje aplinkoje; kitose bibliotekų versijose skaičiai gali nežymiai skirtis.

Patikra	Užregistruota reikšmė	Įrodymo failas
Išoriniai skaidiniai / variantai	50 / 7	verification.json
Modelio pritaikymai	18 951	resources.json
Laikas iki pirmos ataskaitos	26.8 min	resources.json
Konservatyvi RAM viršutinė riba	426.1 MB	resources.json
Vidinės paieškos lentelės	251	verification.json
Nepriklausomas metrikų perskaičiavimas	Atliktas	verification.json

Svarbiausios ribos

- Duomenys apima keturias konkrečias klases ir kontroliuojamą fotografavimą; realaus eismo tinkamumas neįrodytas.
- OpenML lentelėje nėra pradinių vaizdų ir patikimų fotografavimo serijų identifikatorių grupiniam testui.
- Atsitiktinė stratifikacija gali pervertinti veikimą naujam fiziniam automobiliui ar kamerai.
- Praktinė klaidų kaina konkrečiam diegimo scenarijui nenumatyta; Opel-Saab painiojimas gali būti mažiau svarbus nei rūšių supainiojimas.

Gyvo gynimo veiksmai

Studentas turi paaiškinti standartizavimo ir SVM RBF formulės ryšį su `src/models.py`, paleisti dėstytojo pateiktą naują 18 požymių įrašą per `predict.py` (pradinis SVM) arba `START.cmd` 4 pasirinkimą (tiriamasis TabPFN v2) ir gyvai atlikti nedidelį modelio, metrikos arba apdorojimo pakeitimą. Šie veiksmai ataskaitos rengimo metu dar nebuvo atlikti ir priklausys nuo dėstytojo pateikto bandymo.

AI naudojimo auditas

Repository failas `ai_log.md` registruoja priimtus ir atmestus pasiūlymus, nepatikrintas prielaidas bei jų patikrą. `AI_POKALBIU_ISTORIJA.md` saugo ankstyvųjų pokalbių tekstus ir pažymėtas vėlesnių etapų santraukas; pastarosios nėra pažodinis eksportas. Tarp užfiksuotų pataisų: 846, o ne 946 OpenML įrašai; SVM sprendimo balai nėra tikimybės; duomenų standartizavimas negali būti apskaičiuotas prieš CV; ankstesnė balsų lygybės prielaida neatitiko bibliotekos nustatymų.

9. Egzamino kriterijų atitiktis

Kriterijus	Balai	Kur parodyti įrodymai
Duomenų grandinė, baseline, atkuriamumas	10	2, 3 ir 8 skyriai; README.md; verification.json
Bent du intelektualieji metodai	20	3 ir 4 skyriai; trys alternatyvių metodų sąsiuviniai
Korektiškas eksperimentas ir vienodas palyginimas	20	2 ir 4 skyriai; tie patys indeksai; vidinė CV
Rezultatai, abliacija, atsparumas, klaidos	15	4-7 skyriai; lentelės, grafikai ir konkretūs pavyzdžiai
Ribos, rizikos, praktinis tinkamumas	10	7 ir 8 skyriai; duomenų apribojimai ir trikdžių analizė
AI naudojimo auditas	5	ai_log.md ir AI_POKALBIU_ISTORIJA.md
Gyvas gynimas, nematytas testas, mažas pakeitimas	10	Instrukcija 8 skyriuje; veiksmai atliekami tik gynimo metu

Balai paimti iš originalios užduoties, o trečioje skiltyje pateiktos įrodymų vietos. Lentelė nėra pažymio garantija: gyvo gynimo dalį vertins dėstytojas po realaus bandymo.

10. Naujesnė literatūra ir metodų svarstymas

Pradinis klasikinis SVM, MLP ir RBF pasirinkimas buvo pagrįstas bendrais algoritmų šaltiniais. Peržiūrėti du 2024 m. tyrimai, kuriuose taip pat naudotas Vehicle Silhouettes rinkinys. Jų rezultatai nelyginami skaičius prieš skaičių su šiuo darbu: skiriasi skaidymai, duomenų pateikimas ir vertinimo sąlygos.

2024 m. tyrimas	Kodėl svarbus šiam uždaviniui	Sprendimas šiame darbe
Yang ir kt.; DOI 10.32604/cmes.2024.048049	Nagrinėja daugiatikslę požymių atranką; tarp bandymų yra Vehicle Silhouettes. Klaidingų Opel ir Saab prognozių gausa motyvuoja patikrinti, ar mažesnis informatyvių požymių rinkinys padėtų.	Įgyvendinta paprastesnė k požymių atranka mokymo grandinėje ir derinta vidinėje patikroje. Tai straipsnio idėjos adaptacija, o ne jo banginių optimizatoriaus reprodukcija.
Przybyła-Kasperek ir Marfo; DOI 10.1371/journal.pone.0311041	Modifikuotas MLP su vietiniais modeliais taip pat bandytas su Vehicle Silhouettes. Vertinga alternatyva, kai požymiai paskirstyti tarp skirtingų šaltinių.	Tiesiogiai netaikyta, nes čia turime vieną pilną 18 požymių lentelę. Dirbtinis jos skaidymas nepadidintų turimų fizinių objektų įvairovės.

Tiksli praktinė problema: klasifikuoti keturis konkrečius iš modelių transporto priemonių siluėtų išvestų požymių rinkinius. Tai gali patikrinti požymių klasifikavimo grandinę, bet neįrodo veikimo naujų markių automobiliams ar iš kamerų gautiems vaizdams. Opel ir Saab supainiojimas svarbus todėl, kad užduotis reikalauja keturių atskirų klasių.

11. Tobulinimo bandymai ir mokymo kokybė

Pirmiausia tikrintas iš mokymo dalies Opel ir Saab įrašų mokomas porinis specialistas. Jo požymių skaičius, C ir gamma parinkti penkių dalių vidinėje patikroje. Kai pradinis SVM prognozavo vieną iš automobilių, specialistas patikslindavo klasę. Šio varianto išorinis Macro-F1 sumažėjo nuo 0.842 iki 0.831; Opel ir Saab jungtinių prognozių F1 vidurkis sumažėjo nuo 0.719 iki 0.697. Šis variantas atmestas.

Senų 50 vidinių paieškų auditas parodė, kad SVM C=100 - ankstesnio tinklėlio viršutinė riba - laimėjo 48 kartus; gamma=0,01 laimėjo 37 kartus, scale - 13 kartų. RBF tinklui 32 centrai ir plotis 1 laimėjo 50 kartų, vadinasi jo paieškos ribos taip pat riboja išvadą. MLP mokymosi žingsnis 0,01 laimėjo 50 kartų. Šie dažniai aprašo modelio parinkimą, ne nepriklausomą statistinį įrodymą.

Todėl antru tiriamuoju bandymu platesniame SVM tinklėlyje parenkami C iš {10; 100; 1000}, gamma iš {0,003; 0,01; 0,03; scale} ir 12 arba 18 požymių. Požymių atranka, medianos ir standartizavimas išmokstami iš kiekvienos vidinės mokymo dalies. Visi 50 išorinių testų sutampa su pradiniu bandymu.

Požymių atranka visais 50 kartų pasirinko 18 iš 18 požymių: mažesnis rinkinys nepadėjo. Platesniame tinklėlyje C=1000 laimėjo 33 kartus, C=100 - 17 kartų. Taigi pagerėjimas siejamas su platesne SVM parametų paieška, o ne su požymių mažinimu. C vėl dažnai pasirinko viršutinę ribą; tai lieka derinimo ribojimas.

Variantas	Išorinis Macro-F1	Opel F1	Saab F1
Pradinis SVM	0.842	0.716	0.721
Platesnis SVM su atranka	0.852	0.736	0.747

Porinis Macro-F1 pokytis: +0.010; didesnis rezultatas 29 iš 50 skaidinių, mažesnis 12. Apytikslis pataisytas 95 % skirtumo intervalas [-0.008; +0.028] apima nulį. Šis bandymas pasirinktas žinant ankstesnio testo rezultatus, todėl intervalas čia tik aprašomasis, ne nepriklausomas naujas patvirtinimas.

Pirminio MLP parametų audite alpha=0,01 laimėjo 34/50, (32,16) paslėptų vienetų konfigūracija 30/50, mokymosi žingsnis 0,01 - 50/50. Pakartotinai išmokus 50 pasirinktų MLP konfigūracijų, medianinis epochų skaičius buvo 35.5 (intervalas 17-64); pradinė ir galutinė mokymo nuostolių reikšmės krito 50/50 atvejų, konvergencijos perspėjimų 0. Tai neįrodo, kad mokymas optimalus; ankstyvas stabdymas ir ribotas tinklėlis lieka galimi kokybės ribojimai.

Išorinės metrikos apskaičiuotos iš išsaugotų prognozių, o visi trys tiriamieji variantai turi atskirus rezultatų failus. Pradinis results/main/ neperrašytas. Naujiems duomenims galiojantį veikimą reikia tikrinti su nepriklausomai surinktais ir paženklintais siluetais; sintetinių ženklintų pavyzdžių iš tų pačių 846 įrašų šiame darbe neįridėta.

Šaltiniai

Užduotis: PEPfm-26_Kirilas_Sersniovas.docx. Galutinis planas:

Kirilas_Sersniovas_Kolokviumo_planas_papildyti_bandymai_2026-09-28.pdf. Duomenys: OpenML Vehicle ID 54,

<https://www.openml.org/d/54>. Pirminiai tyrimai: <https://doi.org/10.32604/cmes.2024.048049> ir

<https://doi.org/10.1371/journal.pone.0311041>. Klasikiniai modeliai: Cortes ir Vapnik (1995), DOI 10.1007/BF00994018;

Rumelhart ir kt. (1986), DOI 10.1038/323533a0; Moody ir Darken (1989), DOI 10.1162/neco.1989.1.2.281.

A priedas. Originali individuali egzamino užduotis

Žemiau perkeltas visas lietuviškas užduoties tekstas iš pateikto PEPfm-26_Kirilas_Sersniovas.docx. Angliškas to paties dokumento vertimas nekartojamas. Pašalintos tik dokumento formatavimo žymos.

Intelektualiosios sistemos

Individuali 2026-2027 m. užduotis

Studentas: Kirilas Šeršniovas

Grupė: PEPfm-26

Transporto priemonių siluetų klasifikavimas

Vaizdo analizės prototipas turi pagal iš silueto apskaičiuotus geometrinius požymius nustatyti transporto priemonės tipą.

Duomenys ir sprendimo tikslas

- Siūlomas viešas duomenų rinkinys: OpenML Vehicle, <https://www.openml.org/d/54>
- Prognozuojamas rezultatas: Daugiaklasis transporto priemonės tipas.
- Privalomas paprastas atskaitos metodas: kNN ir artimiausių centroidų bazė.
- Svarstylini intelektualieji metodai: SVM, MLP, RBF tinklas, SOM. Galima pasirinkti kitus metodus, jei pasirinkimas pagrįstas literatūra ir eksperimentu.
- Pagrindinės vertinimo kryptys: Macro-F1, balanced accuracy ir painiavos matrica.
- Duomenų skaidymo reikalavimas: Kartotinis stratifikuotas kryžminis vertinimas.
- Svarbiausias probleminis aspektas: Maža imtis ir persidengiančios klasės.

Kolokviumo dalis

Kolokviumui reikia parengti įgyvendinimo planą. Kodo ir galutinių rezultatų dar nereikalaujama, tačiau planas turi būti pakankamai konkretus, kad pagal jį kitas programuotojas galėtų pradėti darbą.

- Suformuluoti problemą, techninį uždavinį ir praktinę sprendimo vertę. Įvardyti neaiškumus, apribojimus ir klaidų kainą.
- Išskaidyti sprendimą į duomenų gavimo, paruošimo, modelio mokymo, vertinimo ir naudojimo etapus. Aiškiai aprašyti įvestį ir išvestį.
- Pateikti 2-4 galimus intelektualiuosius metodus ir paprastą baseline. Kiekvieno metodo tinkamumą pagrįsti patikrintais pirminiais šaltiniais; pateikti DOI arba stabilias nuorodas.
- Pasirinkti pagrindinį metodą ir suformuluoti patikrinamą hipotezę, kuo bei kokiomis sąlygomis jis turėtų pranokti baseline.
- Pateikti pagrindines pasirinkto modelio formules arba taisykles, paaiškinti kintamuosius ir susieti jas su planuojamais programos moduliais.
- Iš anksto aprašyti duomenų skaidymą, preprocessing, metrikas, abliaciją, klaidų analizę, skaičiavimo biudžetą ir didžiausias grėsmes išvadų galiojimui.
- Pateikti AI naudojimo planą: kam AI bus naudojamas, kaip bus tikrinamos citatos, formulės, kodas ir rezultatai.

Galutinio egzamino dalis

Galutiniam egzaminui reikia pateikti veikiančią ir atkuriamą sprendimą bei įrodymus, leidžiančius įvertinti jo ribas.

- Įgyvendinti duomenų paruošimo grandinę, baseline ir bent du intelektualiuosius metodus. Bent vienam modeliui parodyti formules ar taisyklės ryšį su konkrečia kodo vieta.
- Palyginti metodus tuo pačiu duomenų skaidymu ir tomis pačiomis metrikomis. Hiperparametrų parinkimui nenaudoti galutinio testo.

- Atlikti bent vieną abliaciją arba požymių jautrumo bandymą ir bent vieną atsparumo bandymą: triukšmui, trūkstamiems duomenims, laiko ar grupės poslinkiui.
- Pateikti rezultatų lentelę, tinkamą grafiką, klaidų pavyzdžius ir paaiškinti, kodėl pasirinktas metodas laimėjo arba nelaimėjo. Neigiamas rezultatas priimtinas, jei eksperimentas korektiškas.
- Pateikti paleidimo instrukciją, priklausomybių sąrašą, fiksuotas atsiktines sėklas ir vieną komandą pagrindiniam eksperimentui pakartoti. Duomenų failų kopijų teikti nereikia, jei yra atsisiuntimo instrukcija.
- Pateikti AI naudojimo žurnalą: svarbiausios užklauso, priimti ir atmesti pasiūlymai, bent dvi aptiktos AI klaidos arba nepatikrintos prielaidos ir jų patikros būdas.
- Gyvo gynimo metu paaiškinti pasirinktą formulę bei kodą, paleisti dėstytojo pateiktą nematytą bandymą ir atlikti nedidelį modelio, metrikos ar duomenų apdorojimo pakeitimą.

Kolokviumo vertinimas

Kolokviumas vertinamas 10 balų skale. Surinkti balai tiesiogiai sudaro 10 % galutinio dalyko pažymio. Kolokviume vertinamas įgyvendinimo planas; veikiantis kodas ir galutiniai eksperimentų rezultatai dar nereikalingi.

Vertinama kolokviumo dalis: Balai

Problemos formulavimas, apribojimai ir klaidų kaina: 2

Alternatyvūs metodai, baseline ir literatūros pagrindimas: 2

Įvestis, išvestis, formulės arba taisyklės ir būsimo kodo struktūra: 2

Duomenų skaidymo, metrikų, eksperimentų ir rizikų planas: 3

AI naudojimo ir pateiktos informacijos tikrinimo planas: 1

Galutinio egzamino vertinimas

Galutinio egzamino rezultatas vertinamas 90 balų skale ir sudaro 90 % galutinio dalyko pažymio.

Vertinama galutinio egzamino dalis: Balai

Baseline, duomenų grandinė ir atkuriamumas: 10

Bent dviejų intelektualiujų metodų įgyvendinimas: 20

Eksperimento korektiškumas ir vienodos palyginimo sąlygos: 20

Rezultatai, abliacija, atsparumo bandymas ir klaidų analizė: 15

Sprendimo ribos, rizikos ir praktinis tinkamumas: 10

AI naudojimo auditas: 5

Gyvas gynimas, nematytas testas ir nedidelis pakeitimas: 10

Galutinis dalyko rezultatas (%) = kolokviumo balai + egzamino balai. Didžiausias rezultatas: 10 + 90 = 100 balų.

AI įrankius naudoti leidžiama. AI sugeneruotas tekstas, citata ar rezultatas savaime nėra įrodymas. Studentas atsako už duomenų kilmę, kodo veikimą, šaltinių tikrumą ir pateiktas išvadas.

B priedas. Papildomi automobilių klasių atskyrimo bandymai

2026 m. rugsėjo 28-29 d. tiriamasis tęsinys. Pagrindinės ataskaitos 1-11 skyrių ir A priedo rezultatai palikti nepakeisti. Čia pateikiami trys nauji bandymai, atlikti jau žinant ankstesnių bandymų išorinių testų rezultatus. Todėl skaičiai aprašo šį rinkinį, bet nėra nepriklausomas naujo metodo pranašumo patvirtinimas.

Uždavinio ir duomenų ribos

OpenML Vehicle v1 turi 846 įrašus, keturias klases ir 18 iš modelinių transporto priemonių siluetų apskaičiuotų formos požymių. Įvestyje nėra pradinių pikselių ar patikimų rakurso žymų; jų iš 18 skaičių neatkursime. UCI aprašas patvirtina, kad naudoti modeliniai autobusas, furgonas, Opel Manta 400 ir Saab 9000. Darbo išvadų negalima perkelti į realaus kelių eismo vaizdų atpažinimą.

Metodai ir apsauga nuo duomenų nutekėjimo

Visiems trims naujiems metodams atkurti tie patys 5 kartus kartoti 10 dalių stratifikuoti išoriniai skaidiniai. SVM derina C iš {100; 1000; 10000} ir gamma iš {0,003; 0,01; 0,03; scale}; ExtraTrees - 150 medžių, max_features iš {sqrt; visi} ir min_samples_leaf iš {1; 2; 4}. Abiem parametrus parenka penkių dalių vidinė kryžminė patikra pagal Macro-F1. Medianų pildymas ir SVM standartizavimas yra mokymo grandinėje. TabPFN v2 su 4 ansamblio įvertinimais tiesiogiai pritaikomas kiekvienos išorinės mokymo dalies 18 požymių. Šis modelis iš anksto išmokytas kitais sintetiniais duomenimis; jo svoriai yra papildomas metodinis išteklius.

Kiekvieno naujo modelio 50 JSON kontrolinių taškų saugo išorinio testo indeksus, tiesos žymas, prognozes, sėklą, parinktus parametrus ir trukmę. summarize_next_20260928.py patikrina indeksų ir žymų sutapimą su ankstesniu SVM, perskaičiuoja F1 iš prognozių ir sudaro painiavos matricas. Testo objektai nepatenka į to skaidinio modelio mokymą.

Palyginimas ant 50 išorinių testų

Metodas	Macro-F1	Opel F1	Saab F1	Opel-Saab klaidos
Pradinis SVM	0,842	0,716	0,721	563
Opel-Saab specialistas	0,831	0,690	0,705	608
Ankstesnis platesnis SVM	0,852	0,736	0,747	522
Dar platesnis SVM	0,849	0,733	0,743	525
ExtraTrees	0,755	0,547	0,570	839
TabPFN v2	0,869	0,745	0,752	525

Macro-F1 - skaidinių vidurkis. Klasių F1 ir poros klaidos - iš sujungtų penkių kartojimų prognozių; kiekvienas 846 įrašų ten pasirodo po penkis kartus. Paskutinis stulpelis nėra skirtingų objektų skaičius.

Didžiausias stebėtas Macro-F1 šiame rinkinyje: TabPFN v2 (0,869). Modelių reitingas pasirinktas jau matant šių pačių testų balus, todėl negalima jo pateikti kaip patvirtinto naujo bendrinimo rezultato.

TabPFN ypač sumažino autobusų ir furgonų klaidas, tačiau specifinė Opel-Saab painiava liko: 525 tarpusavio klaidos prieš 522 ankstesnio platesnio SVM. Todėl didesnis bendras Macro-F1 nereiškia, kad dviejų automobilių atskyrimo uždavinys išspręstas.


Kaip buvo tobulintas sprendimas

Pradinio SVM Opel ir Saab tarpusavio klaidos sudarė 563 iš 671 visų klaidų. Pirmiausia mokymo dalyje derintas atskiras porinis Opel-Saab klasifikatorius, kuris tikslino SVM automobilių prognozes. Jis padidino šios poros klaidų skaičių iki 608 ir sumažino Macro-F1 iki 0,831, todėl variantas atmestas.

Tada tikrinta 12 arba 18 požymių atranka ir didesnės SVM C reikšmės; atranka visuose 50 išorinių mokymų pasirinko visus 18 požymių, o platesnė C paieška pakėlė Macro-F1 nuo 0,842 iki 0,852. Tai tiriamasis skaitinis pagerėjimas, kurio pataisytas skirtumo intervalas apima nulį. Dar padidinus C ribą iki 10000 rodiklis sumažėjo iki 0,849. Šis neigiamas bandymas parodė, kad paprastas paieškos intervalo plėtimas nebūtinai padeda.


Toliau išbandytas 150 atsitiktinai skaidomų medžių ExtraTrees ansamblis su vidiniu lapo dydžio ir požymių skaičiaus derinimu. Macro-F1 0,755 ir 839 Opel-Saab tarpusavio klaidos reiškia aiškų pablogėjimą; ansamblis nepasirinktas. TabPFN v2, naudodamas oficialius iš anksto išmokytus svorius, pasiekė 0,869 ir pagerino bendrą klasifikavimą. Vis dėlto prieš platesnį SVM Opel-Saab klaidų buvo trimis daugiau, tad šis bandymas nepagrindžia teiginio, kad svarbiausia automobilių atskyrimo problema išspręsta.

Naujų bandymų grafikai



6 pav. Kiekvienas taškas - vieno iš 50 tų pačių išorinių testų Macro-F1 skirtumas nuo ankstesnio platesnio SVM; rombas - vidurkis. Tie patys 846 įrašai kartojasi penkis kartus, todėl taškai nėra nepriklausomi bandymai.

TabPFN vidutiniškai laimi, bet ne kiekviename skaidinyje: 31 geresnis ir 19 blogesnių. Papildomas SVM C plėtimas dažniausiai nekeitė arba blogino rezultatą, o ExtraTrees beveik visuose skaidiniuose atsiliko. Grafikas papildoma vidurkių lentelę, nes rodo rezultatų sklaidą, ne vieną skaičių.



7 pav. Ankstesnio platesnio SVM ir TabPFN v2 painiavos matricos iš tų pačių 4230 išorinių prognozių. Langelyje - prognozių skaičius ir eilutės procentas; raudonai apibrėžta Opel-Saab pora.

TabPFN autobusų teisingų prognozių skaičių padidino nuo 1063 iki 1084, furgonų - nuo 953 iki 988. Tačiau Opel-Saab kryžminių klaidų suma pasikeitė nuo 522 iki 525. Šitaip grafikas paaiškina, kodėl geresnis bendras Macro-F1 nereiškia tikslinio automobilių poros atskyrimo.

Kiek keitėsi rezultatas ir kokie parametrai laimėjo

Didesnis SVM tinklėlis: porinis Macro-F1 pokytis prieš ankstesnį platesnį SVM -0.003; geresnis 6, lygus 33, blogesnis 11 iš 50 skaidinių. Apytikslis pataisytas 95 % intervalas [-0.014; +0.008] Automobilių klasių F1 vidurkio pokytis -0.003, intervalas [-0.023; +0.017]. Intervalai tik aprašomieji, nes metodai parinkti jau matant ankstesnius testus.

ExtraTrees: porinis Macro-F1 pokytis prieš ankstesnį platesnį SVM -0.097; geresnis 1, lygus 0, blogesnis 49 iš 50 skaidinių. Apytikslis pataisytas 95 % intervalas [-0.128; -0.066] Automobilių klasių F1 vidurkio pokytis -0.185, intervalas [-0.244; -0.127]. Intervalai tik aprašomieji, nes metodai parinkti jau matant ankstesnius testus.

TabPFN v2: porinis Macro-F1 pokytis prieš ankstesnį platesnį SVM +0.017; geresnis 31, lygus 0, blogesnis 19 iš 50 skaidinių. Apytikslis pataisytas 95 % intervalas [-0.011; +0.045] Automobilių klasių F1 vidurkio pokytis +0.007, intervalas [-0.045; +0.059]. Intervalai tik aprašomieji, nes metodai parinkti jau matant ankstesnius testus.

Naujame SVM tinklėlyje C=100 laimėjo 14, C=1000 - 18, C=10000 - 18 kartų. Net jei didesnė C riba kartais parenkama, ji nepagerino bendro išorinio Macro-F1 prieš ankstesnį platesnį SVM. Todėl vien tolesnis C didinimas nėra pakankamai pagrįstas.

ExtraTrees min_samples_leaf laimėtojai: 1 - 32/50, 2 - 15/50, 4 - 3/50. Šie dažniai aprašo vidinės paieškos pasirinkimus, o ne išorinės naudos įrodymą.

Klaidų struktūra ir tolesnis duomenų poreikis

Pradiniame SVM 81 įrašas buvo klaidingas visuose penkiuose pakartojimuose, iš jų 73 - Opel arba Saab. Atliekant tik aprašomąją viso rinkinio kaimynų analizę, 72.6 % šių automobilių arčiausias kitos klasės kaimynas buvo arčiau negu savos klasės; tarp nė karto neklydusių automobilių - 38.1 %. Identiškų požymių eilučių nėra. Analizė naudoja visas žymas tik diagnostikai; ji nenaudota modelio mokymui ir neįrodo, kad kurios nors žymos klaidingos.

Naujų ženklintų siluetų negavome, todėl jų neišgalvojome ir nedauginome senų įrašų kaip tariamai nepriklausomų pavyzdžių. Vertingiausias tolesnis bandymas būtų surinkti naujus Opel ir Saab modelių siluetus su rakurso žymomis arba gauti pradinius vaizdus. Iš anksto fiksuotas, pagal objektą ir rakursą grupuotas nepriklausomas testas leistų patikrinti tikrą naudą.

Atkūrimas ir šaltiniai

Komandos: python diagnose_persistent_cars.py; python experiment_next_20260928.py svm_extended; analogiškai extra_trees ir tabpfn_v2; python summarize_next_20260928.py. TabPFN paleisti .venv_tabpfn aplinkoje. Kontroliniai taškai ir suvestinės: results/further_20260928/. TabPFN v2 tyrimas: Hollmann ir kt., Nature (2025), DOI 10.1038/s41586-024-08328-6. Duomenų aprašas: UCI Statlog Vehicle Silhouettes, DOI 10.24432/C5HG6N. Ankstesni du 2024 m. tyrimai ir jų taikymo ribos pateikti pagrindinės ataskaitos 10 skyriuje.