

Transporto priemonių siluetų klasifikavimo atnaujintas įgyvendinimo planas

Intelektualiosios sistemos | Kolokviumo dalis

Studentas: Kirilas Šeršniovas

Grupė: PEPfm-26

Pradinis planas toliau paliktas kaip istorinis 2026 m. rugsėjo mėn. eksperimento sumanymas. Dokumentą pabaigoje pateikta 2026-09-28 redakcija, parengta jau žinant pradinio bandymo rezultatus. Ji nėra pristatoma kaip iš anksto, prieš pamatant bandymo rezultatus, užregistruota hipotezė.

Planuojamas sprendimas

Pagrindinis kandidatas yra atraminių vektorių klasifikatorius SVM su RBF branduoliu. Jis bus lyginamas su dviem privalomais paprastais atskaitos metodais - 5 artimiausių kaimynų klasifikatoriumi ir artimiausio centro klasifikatoriumi - bei dviem alternatyviais intelektualiaisiais metodais: daugiasluoksniu perceptronu MLP ir RBF tinklu. Vertinimas bus atliekamas taikant įdėtinį kartotinį stratifikuotą kryžminį vertinimą, todėl išoriniai bandymo duomenys nebus naudojami nei duomenų paruošimo parametrų, nei hiperparametrų parinkti.

1 Problemos formulavimas

1.1 Praktinė problema ir techninis uždavinys

Reikia sukurti prototipą, kuris pagal vienos transporto priemonės silueto geometrinius požymius nustatytų vieną iš keturių klasių: Opel, Saab, autobusas arba furgonas. Duomenų rinkinyje šioms klasėms naudojamos žymos opel, saab, bus ir van. Tai yra prižiūrimo mokymosi daugiaklasės klasifikacijos uždavinys. Sistema negaus pradinio vaizdo, todėl jos įvestis bus 18 skaitinių formos požymių vektorius, o ne pikseliai.

Praktinė sprendimo vertė - patikrinti, ar iš kompaktiško geometrinių požymių rinkinio galima pakankamai patikimai atskirti transporto priemonių siluetus, kai objektai nufotografuoti įvairiais pasukimo kampais. Toks prototipas gali būti naudojamas kaip ankstyvas klasifikavimo grandinės vertinimas prieš kuriant sudėtingesnę vaizdo sistemą. Jis nėra paruoštas realiam kelių eismo objektų atpažinimui, nes duomenys gauti iš keturių konkrečių modelių sumažintų vaizdų kontroliuojamomis sąlygomis.

1.2 Sėkmės kriterijai

- Pirminė metrika - Macro-F1. Ji kiekvienai klasei suteikia vienodą svorį ir neleidžia didesnei klasei užgožti prastesnio mažesnės klasės rezultato.
- Antrinė metrika - subalansuotas tikslumas (balanced accuracy). Ji yra keturių klasių atpažinimo jautrumų vidurkis.
- Painiavos matrica parodys, kurios klasės painiojamos tarpusavyje, ypač Opel ir Saab.
- Modeliai bus lyginami naudojant tuos pačius išorinius skaidymus, vienodą duomenų paruošimo principą ir tas pačias metrikas.
- Hipotezė bus priimama arba atmetama pagal iš anksto apibrėžtą kriterijų, o ne pagal vieną palankų skaidymą.

1.3 Apribojimai ir neaiškumai

Apribojimas	Poveikis	Valdymo priemonė
Maža imtis	OpenML Vehicle versijoje pateikiami 846 pavyzdžiai. Sudėtingas modelis gali persimokyti.	Naudoti mažas hiperparametrų erdves, regularizaciją ir įdėtinį kryžminį vertinimą.
Persidengiančios klasės	Du lengvųjų automobilių modeliai turi panašius siluetus, todėl jų požymių sritys gali persidengti.	Vertinti ne tik bendrą metriką, bet ir klasių porų klaidas bei sprendimo atstumą.
Susiję vaizdai	Tas pats fizinis modelis stebėtas daugeliu pasukimo kampų. Atsitiktinai skaidant panašūs vaizdai gali patekti į mokymą ir bandymą.	Šią priklausomybę aiškiai nurodyti kaip galiojimo grėsmę. Jei bus atkurti rinkinių e2-e5 identifikatoriai, papildomai atlikti grupinį bandymą.
Ribota populiacija	Klasės atitinka keturis konkrečius modelius, o ne visą transporto priemonių įvairovę.	Išvadų neapibendrinti realioms kameroms, markėms ar nevaldomoms aplinkos sąlygoms.
Tik išvestiniai požymiai	Nėra pirminių vaizdų, todėl negalima patikrinti segmentavimo klaidų ar išmokti naujų vaizdo požymių.	Vertinti tik pateikto 18 požymių vektoriaus klasifikavimo etapą.
Šaltinių neatitikimas	UCI apraše minima 946 vaizdų pradinė imtis, tačiau 100 pavyzdžių buvo sulaukyti, o OpenML pateikia 846.	Kode užfiksuoti OpenML duomenų rinkinio ID 54, versiją 1, eilučių skaičių ir kontrolinę sumą, jei ji pasiekama.

1.4 Klaidų kaina

Kadangi užduotyje nenurodytas konkretus diegimo scenarijus, mokymo metu klaidoms nebus savavališkai priskiriamos finansinės ar saugos kainos. Visoms klasėms bus suteiktas vienodas svoris skaičiuojant Macro-F1 ir subalansuotą tikslumą. Tačiau klaidų analizėje bus naudojama žemiau pateikta praktinė svarbos tvarka.

Klaidos tipas	Santykinė svarba	Paaiškinimas
Autobusas supainiotas su lengvučiu automobiliu arba furgonu	Didelė	Klaidinga plati transporto priemonės kategorija; keičiasi objekto dydžio ir paskirties interpretacija.
Furgonas supainiotas su lengvučiu automobiliu arba autobusu	Vidutinė arba didelė	Neteisinga plati kategorija, tačiau tiksli kaina priklausytų nuo būsimo naudojimo.
Opel supainiotas su Saab arba atvirkščiai	Mažesnė	Abi klasės yra lengvieji automobiliai, tačiau keturių klasių uždavinyje tai vis tiek yra pilna klasifikavimo klaida.

2 Duomenys ir sprendimo grandinė

2.1 Duomenų šaltinis

Bus naudojamas OpenML Vehicle duomenų rinkinys, kurio identifikatorius yra 54, versija 1. OpenML apraše nurodyta, kad požymiai apskaičiuoti iš 128 x 128 pikselių dvejetainių siluetai. Rinkinyje yra 18 sveikųjų skaičių požymių, keturios klasės ir nėra deklaruotų trūkstamų reikšmių. Įgyvendinimo pradžioje šie teiginiai bus patikrinti programiškai, nes metaduomenys nepakeičia faktinės duomenų patikros.

Duomenų rinkinio kilmė bus fiksuojama naudojant OpenML ID, versiją, atsisiuntimo datą, požymių pavadinimų sąrašą, eilučių skaičių ir klasių pasiskirstymą. Tai neleis nepastebimai pakeisti eksperimento duomenų kita rinkinio versija.

2.2 Įvestis ir išvestis

Elementas	Apibrėžimas
Įvesties objektas	Vienas 18 skaitinių požymių vektorius $x \in \mathbb{R}^{18}$.
Požymių turinys	Kompaktiškumas, apskritimiškumas, ašių santykiai, sklaidos ir pailgėjimo santykiai, stačiakampiškumas, mastelio dispersijos, inercijos spindulys, asimetrija, ekscesas ir įdubų santykis.
Privaloma išvestis	Viena klasė iš {Opel, Saab, autobusas, furgonas}. Programoje saugomos pradinės žymos {opel, saab, bus, van}.
Diagnosticinė išvestis	Šeši porinių SVM klasifikatorių sprendimo atstumai. Neapibrėžtumui bus naudojama mažiausia absoliuti paraštė tarp porų, kuriose dalyvauja prognozuota klasė. Šie dydžiai nebus vadinami tikimybėmis.
Vieno įrašo sutartis	18 baigtinių skaitinių reikšmių ta pačia tvarka kaip mokymo metu. Trūkstamos reikšmės, jei atsirastų, pildomos tik mokymo dalyje apskaičiuotomis medianomis.

2.3 Įgyvendinimo etapai

1. Atsisiųsti duomenis pagal OpenML ID 54 ir išsaugoti metaduomenis bei naudotą versiją.
2. Patikrinti schemą, eilučių ir požymių skaičių, duomenų tipus, klasių žymas, pasikartojančias eilutes, trūkstamas ir nebaigtines reikšmes.
3. Sukurti bendrą duomenų paruošimo ir modelio Pipeline objektą, kad medianos ir standartizavimo parametrai būtų apskaičiuojami tik iš atitinkamos mokymo dalies.
4. Sugeneruoti fiksuotus išorinius kartotinio stratifikuoto kryžminio vertinimo skaidymus ir tuos pačius indeksus perduoti visiems metodams.
5. Kiekvienoje išorinėje mokymo dalyje atlikti vidinę hiperparametrų paiešką, parinkti modelį ir tik vieną kartą įvertinti jį išorinėje bandymo dalyje.

6. Sukaupti kiekvieno išorinio bandymo prognozes, Macro-F1, subalansuotą tikslumą, mokymo laiką ir pasirinktus hiperparametrus.
7. Atlikti iš anksto suplanuotą abliaciją, atsparumo bandymą ir klaidų analizę nekeičiant pagrindinio vertinimo protokolo.
8. Sugeneruoti rezultatų lenteles, normalizuotą painiavos matricą, pakartojimo instrukciją ir AI naudojimo žurnalą.
9. Naudojimo etape įkelti išsaugotą Pipeline grandinę, patikrinti vieno įrašo schemą ir pateikti lietuvišką klasės pavadinimą kartu su diagnostiniais sprendimo atstumais bei modelio versija.

3 Planuojami klasifikavimo metodai

3.1 Privalomi atskaitos metodai

Artimiausio centroido klasifikatorius kiekvienai klasei apskaičiuos standartizuotų mokymo objektų vidurkį ir pasirenks arčiausiai esantį centroidą pagal Euklido atstumą. Jis yra skaidrus ir labai greitas, tačiau numano maždaug kompaktiškas, panašaus mastelio klases. Šis modelis parodys, kiek užduoties galima išspręsti vien klasių vidurkiams.

$$\hat{y}(\mathbf{x}) = \arg \min_{k \in \{1, \dots, K\}} \|\mathbf{x} - \boldsymbol{\mu}_k\|_2$$

5 artimiausių kaimynų atskaitos metode bus naudojamas Euklido atstumas ir vienodas kaimynų balsų svoris. Kaimynų skaičius fiksuojamas prieš eksperimentą, kad atskaitos metodas netaptų plačiai derinamu konkurentu. Šis metodas gali atspindėti vietines netiesines ribas, tačiau mažoje imtyje yra jautrus požymių masteliui, triukšmui ir artimų pavyzdžių pasiskirstymui.

5 artimiausių kaimynų metodo literatūros pagrindas yra Cover ir Hart (1967), o centroidais grindžiamo klasifikavimo tinkamumą rodo Tibshirani ir bendraautorų (2002) darbas. Plane naudojamas paprasčiausias artimiausio centroido variantas be centroidų mažinimo.

3.2 Intelektualieji metodai ir pagrindimas

Metodas	Vaidmuo	Kodėl tinkamas	Pagrindinė rizika ir valdymas	Pirminis šaltinis
SVM su RBF branduoliu	Pagrindinis	Maksimalaus tarpo principas ir branduolys leidžia sudaryti netiesinę ribą 18 požymių erdvėje. Regularizacija tinka mažai imčiai, o RBF branduolys gali atskirti persidengiančias klases.	C ir gamma; abu parenkami tik vidinėje kryžminėje patikroje.	Cortes ir Vapnik, 1995
MLP	Alternatyvus	Paslėptas sluoksnis gali išmokyti netiesines požymių sąveikas. Modelis patikrins, ar lankstesnis neuroninis aproksimatorius duoda naudą.	Mažoje imtyje gresia persimokymas ir pradinių svorių variacija; naudojama regularizacija, ankstyvasis stabdymas ir fiksuotos sėklos.	Rumelhart, Hinton ir Williams, 1986
RBF tinklas	Alternatyvus	Lokalių radialinių funkcijų natūraliai modeliuoja klasterius ir netiesines sritis. Centrai gali būti gaunami k vidurkių metodu, o išvesties sluoksnis mokomas reguliuota tiesine regresija.	Rezultatas priklauso nuo centrų skaičiaus, pločio ir klasterizavimo stabilumo.	Moody ir Darken, 1989

3.3 Pagrindinis metodas ir hipotezė

Pagrindiniu metodu pasirenkamas SVM su RBF branduoliu. Pasirinkimą lemia mažas pavyzdžių skaičius, tik 18 požymių ir tikėtina netiesinė klasių riba. SVM sudėtingumas tiesiogiai valdomas C ir gamma parametrais, todėl jį galima derinti ribotoje, iš anksto nustatytoje erdvėje.

Patikrinama hipotezė. Naudojant tik mokymo dalyje apskaičiuotą standartizavimą ir vidinėje kryžminėje patikroje parinktus C bei gamma, SVM su RBF branduoliu vidutinis Macro-F1 per tuos pačius išorinius skaidymus bus bent 0,02 didesnis už geresnio iš dviejų atskaitos metodų rezultatą. Papildomai tikimasi

didesnio subalansuoto tikslumo. Hipotezė bus laikoma pagrįsta tik tada, kai skirtumas bus teigiamas daugumoje penkių pakartojimų ir 95 procentų pataisytas pasikliautinis intervalas neapims nulio. Jei bent viena sąlyga nebus įvykdyta, hipotezė bus atmesta arba laikoma nepatvirtinta.

4 Pagrindinio modelio formulės

4.1 Standartizavimas

Kiekvienas j -asis požymis standartizuojamas naudojant tik konkretaus mokymo skaidymo vidurkį μ_j ir standartinį nuokrypį σ_j . Ta pati transformacija vėliau pritaikoma vidinio arba išorinio bandymo objektams.

$$z_j = \frac{x_j - \mu_j}{\sigma_j}$$

4.2 Minkšto tarpo SVM

Kiekvieno porinio dvejetainio SVM mokymas apibūdinamas minkšto tarpo optimizavimo uždaviniu.

$$\min_{\mathbf{w}, b, \xi} \frac{1}{2} \|\mathbf{w}\|^2 + C \sum_{i=1}^n \xi_i \quad \text{s. t.} \quad y_i(\mathbf{w}^T \phi(\mathbf{z}_i) + b) \geq 1 - \xi_i, \quad \xi_i \geq 0$$

Formulėje n yra mokymo objektų skaičius, $\mathbf{z}_i$ - standartizuotas i -ojo objekto požymių vektorius, $y_i \in \{-1, +1\}$ - konkrečios klasių poros žyma, o $\phi(\mathbf{z}_i)$ - požymių atvaizdavimas į branduolio apibrėžtą erdvę. Vektorius $\mathbf{w}$ ir poslinkis b apibrėžia skiriamąjį paviršių, ξ_i yra leidžiamas i -ojo objekto tarpo pažeidimas, o C valdo modelio sudėtingumo ir mokymo klaidų kompromisą.

Kadangi klasės gali būti atskirtos netiesiškai, skaliarinė sandauga pakeičiama RBF branduoliu. Parametras γ valdo vieno mokymo pavyzdžio įtakos plotį: didelė γ sukuria lokalesnę ir lankstesnę ribą, o maža γ - glotnesnę ribą.

$$K(\mathbf{z}_i, \mathbf{z}) = \exp(-\gamma \|\mathbf{z}_i - \mathbf{z}\|_2^2)$$

RBF branduolyje $\mathbf{z}_i$ yra standartizuotas mokymo objektas, $\mathbf{z}$ - vertinamas objektas, o γ - branduolio pločio parametras. Sprendimo funkciją lemia atraminių vektorių aibė SV , jų koeficientai α_i , porinės žymos y_i , branduolio reikšmės ir poslinkis b . Ženklas $\hat{y}$ nurodo konkrečios klasių poros prognozę.

$$f(\mathbf{z}) = \sum_{i \in SV} \alpha_i y_i K(\mathbf{z}_i, \mathbf{z}) + b, \quad \hat{y} = \text{sign}(f(\mathbf{z}))$$

Keturių klasių uždavinyje bus naudojama porinio klasių lyginimo schema (one-vs-one). Kiekvienai klasių porai mokomas dvejetainis klasifikatorius, todėl keturioms klasėms gaunami šeši poriniai sprendimai. Galutinė klasė parenkama pagal porinių sprendimų balsus; lygybės atveju galutinį sprendimą priima naudojamos bibliotekos predict funkcija; šeši diagnostiniai sprendimo balai nėra kalibruotos tikimybės.

4.3 Vertinimo formulių ryšys su uždaviniu

Kiekvienai klasei k apskaičiuojami preciziškumas P_k , jautrumas R_k ir $F1$. Macro- $F1$ yra keturių klasių $F1$ vidurkis. Subalansuotas tikslumas yra keturių klasių jautrumų vidurkis. $K = 4$, TP_k - teisingai atpažinti k klasės objektai, FN_k - k klasės objektai, priskirti kitai klasei.

$$F1_k = \frac{2P_kR_k}{P_k + R_k}, \quad \text{MacroF1} = \frac{1}{K} \sum_{k=1}^K F1_k, \quad \text{BA} = \frac{1}{K} \sum_{k=1}^K \frac{TP_k}{TP_k + FN_k}$$

4.4 Formulių ir programos modulių sąsaja

Matematinė dalis	Planuojamas modulis	Realizacijos ryšys
$z_j = (x_j - \mu_j) / \sigma_j$	src/data.py ir sklearn Pipeline	StandardScaler.fit mokymo dalyje, transform bandymo dalyje.
SVM optimizavimo uždavinys	src/models.py	SVC(kernel='rbf', decision_function_shape='ovo').

Matematinė dalis	Planuojamas modulis	Realizacijos ryšys
RBF branduolys	src/config.py ir src/models.py	GridSearchCV perduodami C ir gamma kandidatų sąrašai.
f(z) ir poriniai balsai	src/predict.py	predict pateikia klasę, decision_function - diagnostinius balus.
Macro-F1 ir subalansuotas tikslumas	src/evaluate.py	f1_score(average='macro') ir balanced_accuracy_score.
Painiavos matrica	src/evaluate.py ir src/report.py	confusion_matrix su fiksuota klasių tvarka ir normalizavimu pagal tikrąją klasę.

5 Planuojama programos struktūra

Projektas bus suskaidytas taip, kad duomenų gavimas, modelių konstravimas, eksperimentas ir ataskaita būtų atskiri. Pagrindinis eksperimentas bus paleidžiamas viena komanda, o visi parametrai bus saugomi konfigūracijos faile.

```

project/
  configs/main.yaml      # sėklos, skaidymai ir hiperparametrų tinkleliai
  src/data.py            # OpenML gavimas, schema ir patikra
  src/preprocess.py      # trūkstamų reikšmių pildymas ir standartizavimas
  src/models.py          # centroidų, kNN, SVM, MLP ir RBF modeliai
  src/cv.py              # išoriniai ir vidiniai skaidymai
  src/evaluate.py        # metrikos, intervalai ir painiavos matrica
  src/robustness.py      # triukšmo ir trūkstamų reikšmių bandymai
  src/report.py          # lentelės ir grafikai
  tests/                # duomenų nutekėjimo ir metrikų testai
  run_experiment.py      # viena pagrindinio eksperimento komanda
  requirements.txt
  README.md
  ai_log.md

```

5.1 Modulių sąsajos

Funkcija	Grąžinamas objektas	Atsakomybė
load_vehicle(openml_id, version)	X lentelė, y vektorius, metaduomenys	Patikrina 18 požymių ir keturias leistinas klases.
build_pipeline(model_name, params)	sklearn Pipeline	Imputer -> StandardScaler -> klasifikatorius.
make_outer_splits(X, y, seeds)	50 mokymo ir bandymo indeksų porų	10 dalių, 5 pakartojimai, stratifikacija.
tune_inner(X_train, y_train, pipeline, grid)	geriausias modelis ir kryžminės patikros lentelė	5 dalių vidinė kryžminė patikra, optimizuojamas tik Macro-F1.
evaluate_fold(model, X_test, y_test)	prognozės, balai, metrikos	Bandymo dalis naudojama vieną kartą.
aggregate_results(records)	suvestinė ir grafikai	Vidurkiai, sklaida, intervalai, painiavos matrica.

6 Duomenų paruošimo planas

6.1 Pradinė patikra

- Patvirtinti, kad tikslinis stulpelis yra Class ir jame yra tik opel, saab, bus bei van.

- Patvirtinti, kad X turi 18 stulpelių ir visi jie konvertuojami į skaitinį tipą.
- Suskaičiuoti eilučių skaičių, kiekvienos klasės objektus, tikslus dublikatus, trūkstamas ir begalines reikšmes.
- Palyginti požymių minimumus, maksimumus, medianas ir dispersijas. Nulinės dispersijos požymis būtų pašalintas tik mokymo dalyje ir šis sprendimas būtų registruojamas.
- Išsaugoti duomenų metaduomenų JSON, kad kiekvieno paleidimo duomenų kilmę būtų galima patikrinti.

6.2 Duomenų paruošimas be informacijos nutekėjimo

Kiekviename vidiniame ir išoriniame mokyme bus naudojamas vientisas Pipeline: SimpleImputer(strategy='median'), StandardScaler ir klasifikatorius. Nors rinkinyje trūkstamų reikšmių nedeklaruojama, imputatorius užtikrina apibrėžtą elgesį atsparumo bandyme. Medianų, vidurkių ir standartinių nuokrypių negalima apskaičiuoti iš viso rinkinio prieš skaidymą. Pipeline užtikrins, kad šie parametrai būtų išmokti tik iš konkrečios mokymo dalies.

Pradiniame eksperimente požymių atranka nebuvo atliekama. Vėlesniame, aiškiai atskirtame tobulinimo eksperimente ji dedama į mokymo grandinę ir kiekvienoje vidinės patikros dalyje išmokstama iš naujo. Išorinio bandymo duomenys požymiams parinkti nenaudojami.

7 Eksperimentinis vertinimas

7.1 Įdėtinis kartotinis stratifikuotas kryžminis vertinimas

Galutiniam palyginimui bus naudojamas išorinis RepeatedStratifiedKFold su 10 dalių ir 5 pakartojimais. Tai sudarys 50 išorinių bandymų. Kiekvienoje išorinėje mokymo dalyje hiperparametrai bus parenkami atskiru 5 dalių StratifiedKFold. Vidinio skaidymo sėkla bus deterministiškai gaunama iš išorinio pakartojimo ir dalies numerio.

Atskiras galutinis bandymo rinkinys nebus atskiriamas, nes 846 objektų imtyje tai sumažintų mokymo ir vertinimo duomenų kiekį. Vietoje jo kiekvienas išorinis bandymo skaidinys atlieka nematyto galutinio bandymo vaidmenį savo iteracijoje. Joks sprendimas, įskaitant standartizavimą, hiperparametrus, epochų skaičių ar modelio pasirinkimą, negali remtis to skaidinio rezultatu.

Visiems metodams bus perduotos tos pačios 50 indeksų porų. Modelių palyginimas bus porinis: kiekviename išoriniame skaidyme SVM ir atskaitos metodai vertinami tais pačiais objektais. Tai sumažina skirtumą, kurį galėtų sukelti skirtingi atsitiktiniai skaidymai.

7.2 Hiperparametrų planas

Metodas	Planuojama paieška	Pastabos
Artimiausio centro klasifikatorius	Nederinamas	Euklido atstumas; shrink_threshold=None.
kNN	Nederinamas	n_neighbors=5; metric='euclidean'; weights='uniform'.
SVM su RBF branduoliu	$C \in \{0,1; 1; 10; 100\}$; $\gamma \in \{'scale'; 0,001; 0,01; 0,1; 1\}$	20 derinių; vidinės kryžminės patikros tikslas - Macro-F1.
MLP	hidden_layer_sizes $\in \{(16), (32), (32,16)\}$; $\alpha \in \{0,0001; 0,001; 0,01\}$; learning_rate_init $\in \{0,001; 0,01\}$	18 derinių; ReLU, Adam, early_stopping=True, max_iter=2000.
RBF tinklas	centrų skaičius $\in \{8; 16; 32\}$; pločio daugiklis $\in \{0,5; 1; 2\}$; Ridge alpha $\in \{0,001; 0,01; 0,1\}$	27 deriniai; k vidurkių modelis ir visi parametrai mokomi tik vidinėje mokymo dalyje.

7.3 Metrikos ir rezultatų suvestinė

Rodiklis	Vaidmuo	Ataskaitos forma
Macro-F1	Pirminė	Apskaičiuoti kiekvienam išoriniam bandymui; pateikti vidurkį, standartinį nuokrypį ir pasiskirstymą.
Subalansuotas tikslumas	Antrinė	Naudoti kaip nepriklausomą klasių jautrumo patikrą.
Painiavos matrica	Diagnostinė	Sujungti tik išorines prognozes, rodyti absoliučius skaičius ir normalizavimą pagal tikrąją klasę.
Klasių F1 ir jautrumas	Diagnostinė	Nustatyti, ar bendras rezultatas slepia vienos klasės problemą.
Mokymo ir prognozės laikas	Praktinė	Matuoti vienodomis sąlygomis; laikas nebus pagrindinis laimėtojo kriterijus.

Pagrindinis modelių reitingas bus sudaromas pagal vidutinį išorinį Macro-F1. Kai du modeliai skirsis mažiau nei 0,01, praktiniu požiūriu jie bus laikomi panašiais ir bus atsižvelgiama į subalansuotą tikslumą, sklaidą, sudėtingumą bei klaidų pobūdį. Bus pateikti poriniai SVM ir geriausio ataskaitos metodo skirtumai kiekviename skaidyme. Pasikliautinas intervalas bus skaičiuojamas pataisyto kartotinio kryžminio vertinimo metodu, nes 50 skaidinių rezultatai nėra nepriklausomi.

7.4 Ablacija ir požymių jautrumas

Privaloma pagrindinė abliacija lygins tą patį SVM su RBF ir tiesiniu branduoliu, paliekant tuos pačius išorinius skaidymus ir tą patį duomenų paruošimą. Taip bus tikrinama, ar nauda kyla iš netiesinės ribos, o ne vien iš SVM regularizacijos. Papildomai bus paleistas SVM be StandardScaler. Šis bandymas parodys standartizavimo svarbą skirtingo mastelio geometriniais požymiais.

Požymių jautrumui kiekviename išoriniame bandyme bus skaičiuojama požymio svarba pagal permutaciją: po vieną požymį maišant tik bandymo skaidinyje bus matuojamas Macro-F1 sumažėjimas. Reikšmės bus agreguojamos per skaidymus. Ši analizė nebus naudojama modeliui perrinkti, todėl išorinio bandymo informacija negrįš į mokymą.

7.5 Atsparumo bandymai

Bandymas	Procedūra	Vertinimas
Matavimo triukšmas	Į standartizuotus išorinio bandymo požymius pridėti $N(0, \sigma^2)$ triukšmą, kai $\sigma \in \{0,05; 0,10; 0,20\}$.	Macro-F1 ir subalansuoto tikslumo sumažėjimas nuo pradinių duomenų rezultato. Kiekvienam lygiui naudoti 20 fiksuotų triukšmo realizacijų.
Trūkstanti požymiai	Atsitiktinai paslėpti 5 ir 10 procentų išorinio bandymo langelių. Pildyti tik mokymo dalies medianomis.	Metrikų kritimas ir labiausiai jautrūs požymiai. Visiems modeliams slėpti tas pačias reikšmes.

7.6 Klaidų analizė

- Sudaryti bendrą ir pagal tikrąją klasę normalizuotą painiavos matricą iš išorinių prognozių.
- Kiekvienai klasių porai apskaičiuoti klaidų skaičių ir dalį. Atskirai nagrinėti Opel-Saab porą.
- Atrinkti po 10 mažiausio sprendimo tarpo teisingų prognozių ir 10 didžiausio užtikrintumo klaidų. Tai padės atskirti ribinius objektus nuo galimų duomenų anomalijų.
- Palyginti klaidingų ir teisingų objektų požymių skirstinius bei požymių svarbą pagal permutaciją. Išvada bus aprašomoji, o ne priežastinė.
- Patikrinti, ar klaidos koncentruojasi konkrečiuose pasikartojimuose arba prie požymių skirstinių kraštų.

7.7 Skaičiavimo biudžetas ir atkuriamumas

Planuojama naudoti Python, scikit-learn, pandas, NumPy, SciPy, matplotlib ir seaborn. Eksperimentas skirtas įprastam procesoriui; GPU nereikalingas. Pirminė viršutinė riba - 20 000 modelio pritaikymų, ne daugiau kaip 60 minučių keturių branduolių procesoriuje ir ne daugiau kaip 2 GB operatyviosios atminties. Pirmas vieno išorinio skaidymo bandomasis paleidimas bus naudojamas laikui prognozuoti; jei biudžetas viršijamas, tinklėliai bus mažinami iš anksto aprašyta tvarka, o pakeitimas registruojamas prieš visą eksperimentą.

- Pagrindinės sėklos: 2026, 2027, 2028, 2029 ir 2030 - po vieną kiekvienam išoriniam pakartojimui.
- Programų versijos bus užfiksuotos requirements.txt arba environment.yml faile.
- Kiekvienas paleidimas išsaugos konfigūraciją, Git revizijos identifikatorių, duomenų metaduomenis ir tarpinius CSV rezultatus.
- Pagrindinė komanda bus `python run_experiment.py --config configs/main.yaml`.
- Vienetiniai testai tikrins metrinę funkcijų rezultatus žinomame mažame pavyzdyje, indeksų nepersidengimą ir tai, kad transformatoriai mokytų tik mokymo indeksais.

8 Grėsmės išvadų galiojimui

Grėsmė	Galimas poveikis	Kontrolė
Duomenų nutekėjimas	Išpūstos metrikos, jei skalė, trūkstamų reikšmių pildymas ar atranka apskaičiuota iš bandymo dalies.	Viena Pipeline grandinė, įdėtinė kryžminė patikra ir indeksų testai.
Hiperparametrų persimokymas	Platus tinklėlis gali prisitaikyti prie vidinių skaidymų.	Riboti tinklėliai, viena derinimo metrika ir išorinė kryžminė patikra.
Skaidinių priklausomybė	50 rezultatų nėra 50 nepriklausomų eksperimentų.	Porinis vertinimas ir pataisytas intervalas; nepateikti naivaus t testo.
Panašūs to paties modelio vaizdai	Atsitiktinė stratifikacija gali perversinti gebėjimą atpažinti naują fizinį modelį.	Aiškiai apriboti išvadą; jei galima, papildomas grupinis testas pagal vaizdų seriją.
Vienos metrikos optimizavimas	Modelis gali pagerinti Macro-F1, bet pabloginti svarbios klasės jautrumą.	Kartu pateikti subalansuotą tikslumą, klasių metrikas ir painiavos matricą.
MLP atsitiktinumas	Rezultatas gali priklausyti nuo pradinių svorių.	Fiksuotos sėklos; pasirinktam MLP pakartoti mokymą trimis inicializacijomis kiekvienoje vidinėje atrankoje, jei leidžia biudžetas.
Apibendrinimas	Keturi modeliai ir kontroliuojama kamera neatspindi realaus eismo.	Neteigti realaus diegimo tinkamumo; rekomenduoti naują nepriklausomą duomenų rinkinį.

9 AI naudojimo ir tikrinimo planas

AI bus naudojamas kaip pagalbinė priemonė planui, kodo ruošiniams, vienetinių testų idėjoms ir tekstų redagavimui. AI pateiktas teiginys, citata, formulė arba skaičius nebus laikomas įrodymu. Galutinę atsakomybę už šaltinius, kodą ir rezultatus išlaiko studentas.

AI naudojimo sritis	Privaloma žmogaus patikra
Literatūros paieškos raktažodžiai ir santraukos	Kiekvieną šaltinį atverti leidėjo, DOI arba oficialioje saugykloje; patikrinti autorius, metus, pavadinimą ir ar šaltinis tikrai pagrindžia konkretų teiginį.
Formulių paaiškinimas	Sutikrinti su pirminiu straipsniu ir pasirinktos bibliotekos dokumentacija; ranka paaiškinti kiekvieną simbolį ir ribinį atvejį.

AI naudojimo sritis	Privaloma žmogaus patikra
Kodo ruošiniai	Paleisti mažame sintetiniame rinkinyje, pridėti vienetinius testus, atlikti kodo peržiūrą ir patikrinti mokymo bei bandymo indeksus.
Hiperparametrų pasiūlymai	Priimti tik tuos diapazonus, kurie įrašyti plane prieš visą eksperimentą ir telpa į biudžetą. Atmesti rezultatų pagrindu pasiūlytą tinklėlį, jei jis naudotų išorinę bandymo dalį.
Rezultatų interpretacija	Skaičius generuoti tik iš išsaugotų CSV failų patikrintu skriptu. Rankiniu būdu perskaičiuoti bent vieno skaidymo painiavos matricą ir metrikas.
Ataskaitos redagavimas	Patikrinti, kad AI nepakeitė sąlyginių teiginių į kategoriškus ir nepridėjo neatliktų eksperimentų.

9.1 AI naudojimo žurnalas

Faile `ai_log.md` kiekvienam reikšmingam naudojimui bus registruojama data, užklausa, AI atsakymo santrauka, priimtas arba atmestas pasiūlymas, patikros šaltinis ir priimtas sprendimas. Aptiktos AI klaidos ar nepatiktos prielaidos taip pat bus įrašomos kartu su jų patikros būdu.

10 Literatūra

1. Mowforth, P. ir Shepherd, B. Statlog Vehicle Silhouettes duomenų rinkinys. UCI Machine Learning Repository. DOI: <https://doi.org/10.24432/C5HG6N>
2. Siebert, J. P. 1987. Vehicle Recognition Using Rule Based Methods. Turing Institute Research Memorandum TIRM-87-018. Stabili nuoroda: <https://eprints.gla.ac.uk/91397/>
3. Cover, T. M. ir Hart, P. E. 1967. Nearest Neighbor Pattern Classification. IEEE Transactions on Information Theory, 13(1), 21-27. DOI: <https://doi.org/10.1109/TIT.1967.1053964>
4. Tibshirani, R., Hastie, T., Narasimhan, B. ir Chu, G. 2002. Diagnosis of multiple cancer types by shrunken centroids of gene expression. Proceedings of the National Academy of Sciences, 99(10), 6567-6572. DOI: <https://doi.org/10.1073/pnas.082099299>
5. Cortes, C. ir Vapnik, V. 1995. Support-Vector Networks. Machine Learning, 20, 273-297. DOI: <https://doi.org/10.1007/BF00994018>
6. Rumelhart, D. E., Hinton, G. E. ir Williams, R. J. 1986. Learning representations by back-propagating errors. Nature, 323, 533-536. DOI: <https://doi.org/10.1038/323533a0>
7. Moody, J. ir Darken, C. J. 1989. Fast Learning in Networks of Locally-Tuned Processing Units. Neural Computation, 1(2), 281-294. DOI: <https://doi.org/10.1162/neco.1989.1.2.281>
8. Nadeau, C. ir Bengio, Y. 2003. Inference for the Generalization Error. Machine Learning, 52, 239-281. DOI: <https://doi.org/10.1023/A:1024068626366>
9. Brodersen, K. H., Ong, C. S., Stephan, K. E. ir Buhmann, J. M. 2010. The Balanced Accuracy and Its Posterior Distribution. ICPR. DOI: <https://doi.org/10.1109/ICPR.2010.764>

2026 m. rugsėjo 28 d. strategijos atnaujinimas

Pradinis bandymas parodė, kad iš 18 iš anksto apskaičiuotų silueto požymių SVM klasifikuoja autobusus ir furgonus gerai, tačiau dažnai supainioja du konkrečius lengvųjų automobilių modelius. Todėl antrame etape tikrinamas požymių parinkimas ir platesnis modelio reguliavimas. Joks šio etapo rezultatas nėra naujų fizinių automobilių ar realaus kelių eismo atpažinimo įrodymas.

Naujesni tyrimai ir metodo pasirinkimas

Tyrimas	Kodėl aktualus	Sprendimas
Yang ir kt., 2024; DOI 10.32604/cmes.2024.048049	Vehicle Silhouettes taikoma daugiatikslė požymių atranka; mažiau nereikšmingų požymių gali padėti atskirti persidengiančias klases.	Tikrinama mažesnė, skaidriai įgyvendinta atrankos alternatyva. Tai nėra straipsnio banginių optimizatoriaus reprodukcija.
Przybyła-Kasperek ir Marfo, 2024; DOI 10.1371/journal.pone.0311041	Vehicle Silhouettes naudotas modifikuotam MLP su vietinių modelių jungimu; rodo, kad įprastas MLP nėra vienintelė neuroninė alternatyva.	Nereprodukuojama, nes mūsų duomenys nėra nepriklausomose skirtingų požymių lentelėse. Tyrimas pagrindžia tolesnę alternatyvą, jei atsirastų toks duomenų scenarijus.

Patikrintos hipotezės ir rezultatai

Pradinio SVM išorinis Macro-F1 buvo 0,842; Opel ir Saab sujungtų penkių kartojimų F1 vidurkis – 0,719. Atskirai, vien iš mokymo duomenų mokytas šių dviejų klasių specialistas su požymių atranka pasiekė 0.831 bendrą Macro-F1, palyginti su 0.842 pradiniu modeliu. Tai neigiamas rezultatas: specialistas atmetamas.

Pradinio SVM C=100 buvo parinktas 48 iš 50 išorinių skaidinių. Todėl išbandyta platesnė C paieška, kurioje požymių skaičius, C ir gamma parenkami penkių dalių vidine kryžmine patikra. Naujo varianto išorinis Macro-F1 buvo 0.852; pradinio – 0.842. Atranka visais 50 atvejų pasirinko 18 iš 18 požymių; pagerėjimas siejamas su platesniu C ir gamma derinimu, ne su sumažintu požymių rinkiniu. Apytikslis pataisytas 95 % porinio skirtumo intervalas [-0.008; +0.028] apima nulį. Pakartotinė paieška yra tiriamoji, nes ankstesnio bandymo rezultatai jau buvo žinomi.

Atnaujinta eksperimentinė tvarka

- Visiems variantams naudojami tie patys 5×10 išoriniai stratifikuoti skaidiniai. Kiekviename skaidinyje mokymo ir testo indeksai nesikerta.
- Trūkstamų reikšmių pildymas, standartizavimas ir požymių atranka atliekami modelio grandinėje; visi jų parametrai nustatomi tik iš atitinkamos mokymo dalies.
- C, gamma ir pasirenkamų požymių skaičius derinami tik penkių dalių vidinėje kryžminėje patikroje pagal Macro-F1. Išorinis testas naudojamas rezultatui apskaičiuoti.
- Nauji palyginimai laikomi tiriamaisiais; dėl to paties rinkinio pakartotinio naudojimo jų negalima vadinti nepriklausomu nauju patvirtinimu. Patikimesniam praktinio veikimo vertinimui reikia naujų ženklintų transporto priemonių vaizdų ir grupinio skaidymo.
- Pateikiami visi bandyti variantai, įskaitant pablogėjusį specialistą, ir neperrašomi senieji rezultatai. Naujas metodas neįtraukiamas į pradinio 18 951 pritaikymo biudžeto skaičių.

Metrikų ir klaidų interpretacija

Preciziškumas atsako, kokia dalis modelio Opel prognozių buvo tikri Opel. Jautrumas atsako, kokia dalis tikrų Opel buvo aptikta. F1 yra šių dviejų rodiklių harmoninis vidurkis. Macro-F1 – keturių klasių F1 vidurkis, o subalansuotas tikslumas – keturių jautrumų vidurkis. Šie rodikliai skaičiuojami išorinėse bandymo dalyse; skaitinis pavyzdys pateiktas atnaujintoje egzamino ataskaitoje.

Didžiausia praktinė riba lieka Opel ir Saab painiojimas. Esamas duomenų rinkinys neturi pradinių vaizdų, todėl naujų vaizdo požymių ar tikro papildomų kamerų pavyzdžių rinkinio neįmanoma sąžiningai sukurti iš tų pačių 18 skaičių. Papildomi duomenys turi būti nepriklausomai surinkti ir paženklinti.

Atkūrimas ir tikrinimas

Pagrindinis istorinis bandymas: `python run_experiment.py --config configs/main.yaml`. Nauji tiriamieji bandymai: `python improve_cars.py` ir `python tune_svm.py`. Parametrų bei mokymo diagnostika: `python audit_training.py`. Išsaugotos prognozės, pasirinktų parametrų lentelės ir suvestinės pateiktos `results/` kataloge. Kodas, citatos, rezultatai ir duomenų nutekėjimo patikros turi būti peržiūrėti prieš pateikiant darbą; gyvo gynimo veiksmai atliekami su dėstytojo įrašu.